Instituto Eldorado · UnB

Residência de IA · Turma 2

Challenge 2: Qualidade de Vida

Relatório de Projeto

Semana 2 · Demonstração do RAG do Miau-ricio (EconoMIA)

Equipe

Guilherme Barros

Isabel Azar

Mariah Gladys

Paulo Vitor Gomes

Pedro Lucas Dourado

BRASÍLIA

2026

SUMÁRIO

1. Introdução
2. Entregáveis da semana 2
3. Arquitetura da solução
4. Base de conhecimento
5. Pipeline de ingestão, chunking e embeddings
6. Demonstração
    6.1 Pergunta de conservação
    6.2 Pedido de refeição com vários ingredientes
    6.3 Pergunta respondida por uma fonte nova
    6.4 Pergunta fora da base (RN11)
    6.5 Pergunta de preço (RN04)
    6.6 Tela no celular
    6.7 Linha de comando e API
7. Avaliação
8. Limitações e próximos passos
9. Como reproduzir

1. Introdução

O EconoMIA é um assistente de planejamento de compras de supermercado. A essential question do grupo é: *como podemos utilizar inteligência artificial para otimizar o orçamento de compras e reduzir o desperdício de alimentos por meio da gestão automatizada de inventário doméstico e rastreamento de preços locais?*

Na semana 2, o grupo construiu o primeiro mecanismo de RAG (*Retrieval-Augmented Generation*) do projeto, que atende o **Miau-ricio**, o agente de receitas e alimentação. Ele responde perguntas como "o que faço com arroz, ovo e cenoura?", "como guardar folhas verdes?" ou "posso dar açúcar para um bebê?" usando **somente** trechos de uma base de conhecimento curada, e sempre mostra as fontes usadas.

Este relatório demonstra o sistema em funcionamento: a consulta enviada, os trechos recuperados com o score de similaridade, a resposta baseada neles e as fontes citadas. As regras de negócio citadas (RN) estão no modelo de domínio do projeto (`docs/arquitetura/modelo-de-dominio.md`):

- **RN01**: o LLM nunca calcula valores. Contas, comparações e a contagem dos ingredientes que faltam são funções determinísticas.
- **RN04**: o RAG não é fonte de preço atual. Perguntas de preço recebem um aviso, sem passar pela base.
- **RN10**: toda resposta baseada na base cita a fonte, e as fontes são montadas pelo código, não escritas pelo LLM.
- **RN11**: sem informação na base, o sistema diz que não encontrou, em vez de inventar.

2. Entregáveis da semana 2

Entregável	Situação	Onde está
Artefatos		
Base de conhecimento curada	**Entregue**	`data/base-conhecimento/FONTES.md` : licença, instituição, ano, link e motivo de confiança de cada fonte. A curadoria descarta receitas duplicadas e incompletas (seção 4).
Mínimo de 20 documentos-fonte	**Entregue**	20 fontes, conferidas por um cenário BDD (`catalogo_de_fontes()`).
Estratégia de chunking	**Entregue**	`docs/semana-2/estrategia-rag.md` , seção 4; resumo na seção 5 deste relatório.
Estratégia de embeddings	**Entregue**	`docs/semana-2/estrategia-rag.md` , seção 5; resumo na seção 5.
Banco vetorial implementado	**Entregue**	Qdrant 1.20, coleção `base_conhecimento_e5` com 6.151 trechos.
Demonstração		
Consulta submetida ao sistema	**Entregue**	Tela de perguntas (`frontend/`), rota `POST /api/v1/receitas/perguntas` , linha de comando e notebook. Seção 6.
Recuperação dos chunks mais relevantes	**Entregue**	Painel "Trechos recuperados", com o score de cada trecho, o limiar e quais foram citados. Seção 6.
Resposta fundamentada no conteúdo recuperado	**Entregue**	O LLM recebe só os trechos numerados e devolve quais usou (JSON). Seções 6 e 7.
Evidência das fontes utilizadas	**Entregue**	Citações `[n]` ligadas à lista de fontes, com página, link e licença. Seção 6.
Documentação		
Diagrama de arquitetura	**Entregue**	`docs/arquitetura/visao-geral.md` , seção 2.1. Seção 3 deste relatório.
Pipeline de ingestão de dados	**Entregue**	`docs/semana-2/pipeline-ingestao.md` . Seção 5 deste relatório.

3. Arquitetura da solução

O EconoMIA é um monolito modular em Python: cada contexto do domínio é um módulo com as camadas `dominio`, `aplicacao` e `infraestrutura`. Da arquitetura completa (orquestrador, fila, PostgreSQL, Langfuse), a semana 2 entregou o caminho da pergunta ao Miau-ricio:

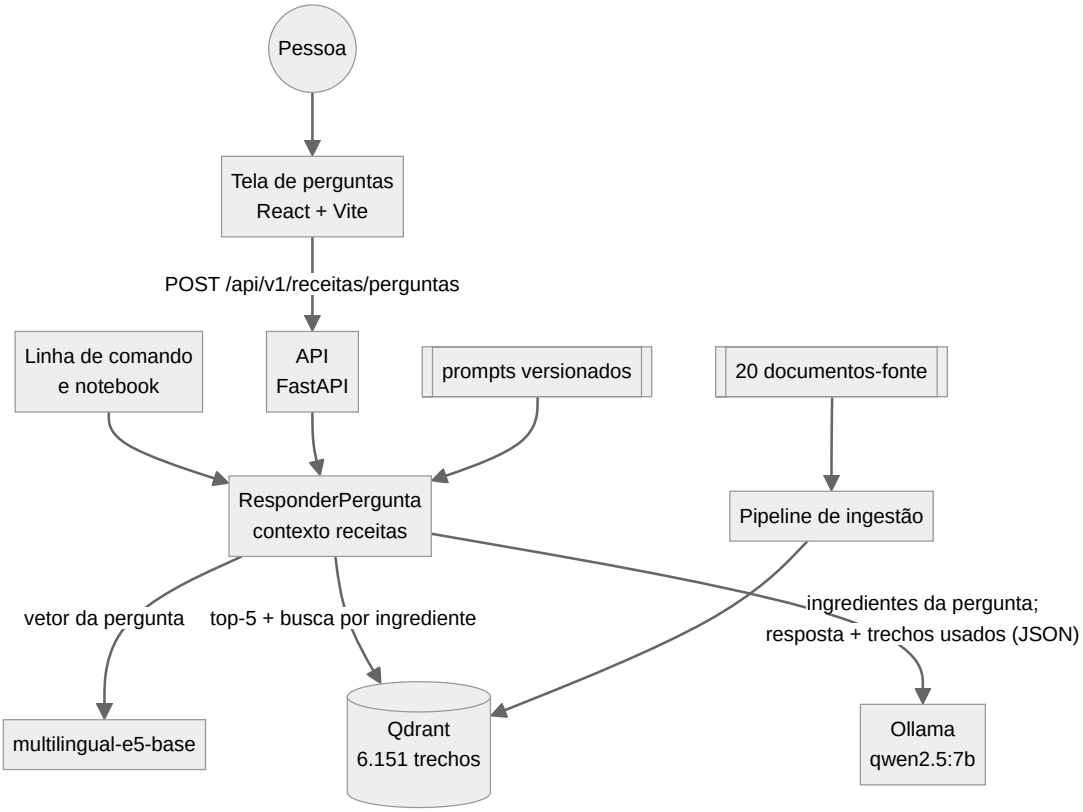


Figura 1. Arquitetura do RAG em funcionamento na semana 2.

O caso de uso `ResponderPergunta` concentra as regras, na ordem em que são aplicadas:

1. **Pergunta de preço?** Uma regra determinística responde com o aviso da RN04, sem consultar a base.
2. **Busca.** O e5 gera o vetor da pergunta, e o Qdrant devolve os 5 trechos mais parecidos (similaridade de cosseno).
3. **Limiar (RN11).** Só seguem os trechos com score de pelo menos 0,845. Sem nenhum, a resposta é "não encontrei".
4. **Busca por ingrediente.** Se a pergunta lista dois ou mais ingredientes, extraídos pelo LLM em JSON, o sistema busca uma receita para cada um.
5. **Desempate.** Entre receitas com score parecido, vem primeiro a que tem menos ingredientes faltando, contados por código (RN01).
6. **Redação.** O LLM recebe a pergunta e os trechos numerados e devolve um JSON com `encontrou`, `resposta` e `trechos_usados`.
7. **Fontes (RN10).** O código troca os números citados pelas fontes (título, instituição, ano, página, link e licença) e lista os ingredientes que faltam.

Peça	Tecnologia	Arquivo
Tela de perguntas	React 18, Vite 5, TypeScript	`frontend/src/App.tsx`
API	FastAPI (documentação em `/docs`)	`src/economia/api/app.py`
Caso de uso	Python 3.12	`src/economia/receitas/aplicacao/responder_pergunta.py`
Embeddings	`intfloat/multilingual-e5-base` (768 dimensões)	`receitas/infraestrutura/embeddings_e5.py`
Banco vetorial	Qdrant 1.20, distância cosseno	`receitas/infraestrutura/repositorio_qdrant.py`
LLM	Ollama com `qwen2.5:7b`, local	`compartilhado/infraestrutura/llm_ollama.py`
Prompts	Markdown versionado	`prompts/miau-ricio/`

4. Base de conhecimento

A base tem **20 documentos-fonte**: duas bases de receitas e 18 textos de orientação de instituições públicas e de revistas científicas. Cada fonte tem a licença conferida no próprio documento ou na página editorial, e só entrou depois disso. Os 13 documentos acrescentados nesta semana foram escolhidos, num catálogo de 21 montado pela equipe, pelo impacto nas perguntas de quem planeja as compras e cozinha em casa. Ficaram de fora estudos de processos industriais e textos sobre programas institucionais.

#	Documento	Instituição	Ano	Trechos
1	afrodite.json (receitas brasileiras)	Repositório no GitHub	—	1.004
2	RecipeNLG (amostra de 3.000 receitas)	Poznań University of Technology	2020	3.000
3	Guia Alimentar para a População Brasileira	Ministério da Saúde	2014	167
4	Na cozinha com as frutas, legumes e verduras	Ministério da Saúde e UFMG	2016	137
5–7	Hortaliça não é só salada (Geladeira e Congelador) e Recomendações para compras e armazenamento	Embrapa e Ceagesp	2020	38
8	Guia Alimentar para Crianças Menores de 2 Anos	Ministério da Saúde	2019	453
9	Protocolos de Uso do Guia Alimentar (adultos)	Ministério da Saúde e USP	2021	67
10	Laboratório de Inovação: frutas, legumes e verduras	OPAS, MS, INCA, FAO e WFP	2022	130
11	Tabela Brasileira de Composição de Alimentos (TACO)	NEPA, Unicamp	2011	430
12	Food Safety Handbook (capítulo 3)	International Finance Corporation	2020	411
13–17	Artigos sobre ultraprocessados, pandemia, comensalidade, ambiente escolar e higiene	RACA, Fiocruz	2019–2024	225
18–19	Percepção de riscos e rastreabilidade; higiene em serviços de alimentação	Brazilian Journal of Food Technology	2012–2013	63
20	Campanha para redução de desperdício	Cadernos Saúde Coletiva	2022	26
Total na coleção				**6.151**

Curadoria das receitas: saem as duplicadas (mesmo título e ingredientes) e as incompletas, sem ingredientes ou sem modo de preparo. No afrodite.json, só 1.004 das 8.183 receitas estão completas; ao todo, 6.175 receitas foram descartadas. Os ingredientes divididos em subseções ("Massa:", "Recheio:") são juntados numa lista só.

Licenças. As fontes têm licença CC BY, CC BY-NC-SA, CC BY-NC-ND ou reprodução livre com citação, o que atende ao uso acadêmico. Um produto comercial precisará trocar as fontes não comerciais. A lista completa, com os links, está em `data/base-conhecimento/FONTES.md`.

5. Pipeline de ingestão, chunking e embeddings

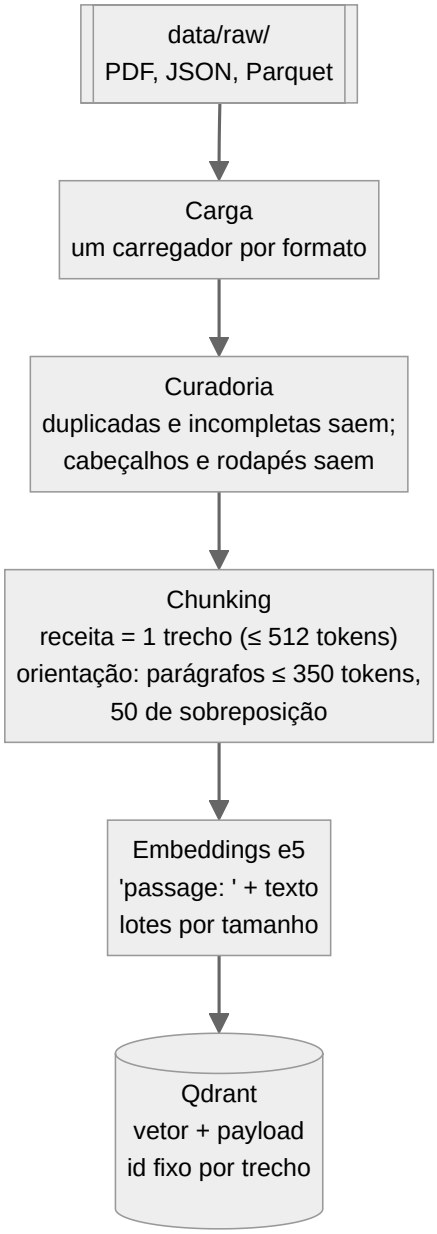


Figura 2. Pipeline de ingestão (`docs/semana-2/pipeline-ingestao.md`).

1. **Coleta.** Os arquivos são baixados dos links oficiais para `data/raw/`, pasta fora do git. O repositório guarda os links, as licenças e os comandos de download.
2. **Carga.** Cada formato tem um carregador: JSON (afrodite.json), Parquet (RecipeNLG, amostra fixa com semente 42), o Guia Alimentar pelas seções do sumário e os demais PDFs com uma seção por página, guardando o capítulo e a página para a citação.
3. **Curadoria.** Saem receitas duplicadas e incompletas; nos PDFs, saem cabeçalhos, rodapés e números de página, e as linhas quebradas são unidas.
4. **Chunking.** Uma receita é um trecho só, porque separar os ingredientes do modo de preparo atrapalhava a busca. Os textos de orientação são divididos por seção e parágrafo, em trechos de até 350 tokens com 50 de sobreposição, sem juntar duas seções.

5. **Embeddings.** A versão 1 usa o `multilingual-e5-base`: roda na CPU, sem GPU, e busca entre idiomas (pergunta em português, receita em inglês). A comparação com o `qwen3-embedding:4b`, prevista na estratégia, ficou para uma próxima rodada. Os prefixos `query:` e `passage:` fazem parte do treino do modelo.
6. **Gravação.** Cada trecho vai para o Qdrant com um id fixo (UUID v5), o que permite reindexar sem duplicar, e com o payload da fonte, usado para citar.

indexação da base

```
$ poetry run python -m economia.receitas.cli indexar --lote 32        # base da versão 1 (7 fontes)
4346 trechos (6175 receitas incompletas descartadas)
base_conhecimento_e5: 4346/4346
4346 trechos gravados em base_conhecimento_e5 em 379 s (4346 na coleção)

$ poetry run python -m economia.receitas.cli indexar --so-orientacao --lote 32   # base ampliada (#16)
2147 trechos (0 receitas incompletas descartadas)
base_conhecimento_e5: 2147/2147
2147 trechos gravados em base_conhecimento_e5 em 247 s (6151 na coleção)
```

Saída do comando `indexar`: a base da versão 1 (7 fontes) e a ampliação para 20 fontes, que reindexa só a orientação.

6. Demonstração

A demonstração usa a tela de perguntas. Cada cenário mostra os quatro itens pedidos:

- 1 a consulta enviada;
- 2 os trechos recuperados, com o score;
- 3 a resposta baseada nos trechos;
- 4 as fontes usadas.

Os prints foram tirados em 10/11/2026, com o Qdrant, o Ollama (`qwen2.5:7b` na GPU), a API e a tela rodando na máquina local. Como o LLM gera texto, a redação de uma resposta pode mudar de uma execução para outra; os trechos recuperados e as fontes não mudam.



Figura 3. Tela inicial: campo da pergunta e exemplos para clicar.

6.1 Pergunta de conservação

1 "Como guardar folhas verdes na geladeira?"

2 A busca devolveu 5 trechos de orientação acima do limiar de 0,845: do "Na cozinha com as frutas, legumes e verduras" (MS e UFMG) e de dois materiais da Embrapa. 3 A resposta usa o trecho que fala de folhas: geladeira, saco plástico transparente, 5 a 7 dias. 4 A fonte traz o capítulo, a página (p. 20), o link e a licença. No painel, o trecho citado aparece marcado como "citado [1]".

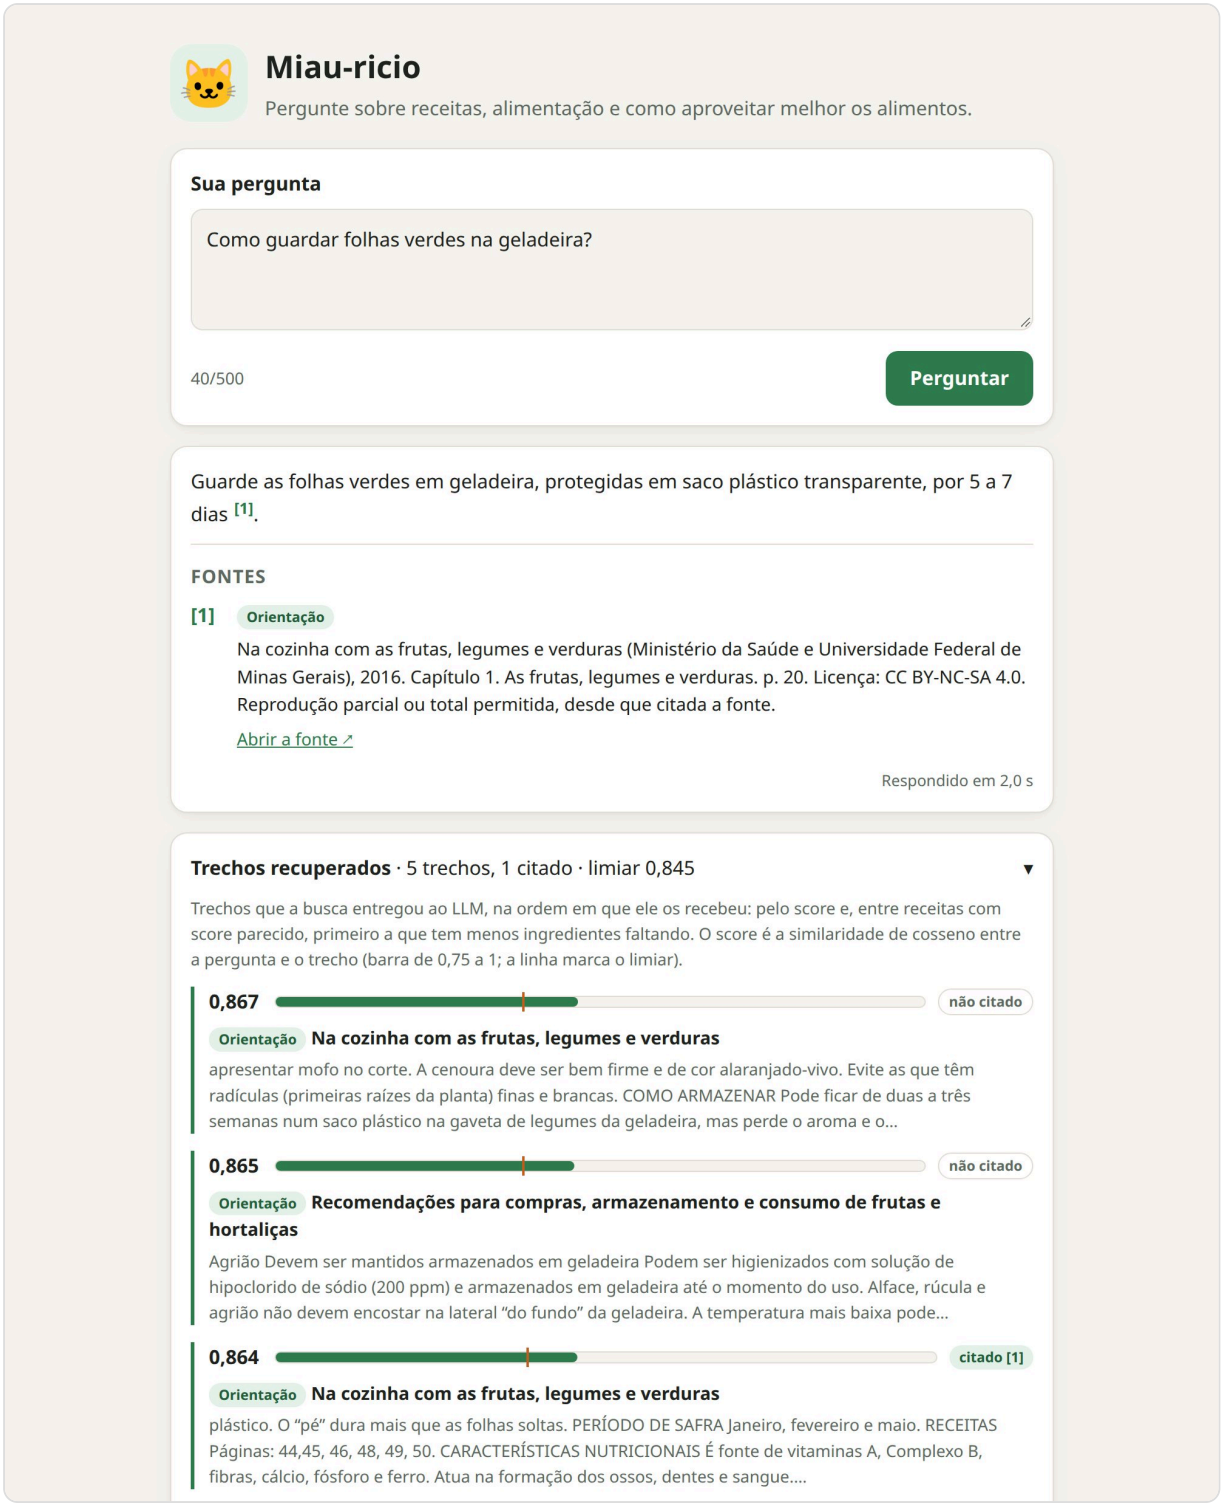


Figura 4. Pergunta, resposta, fonte e começo do painel de trechos recuperados.

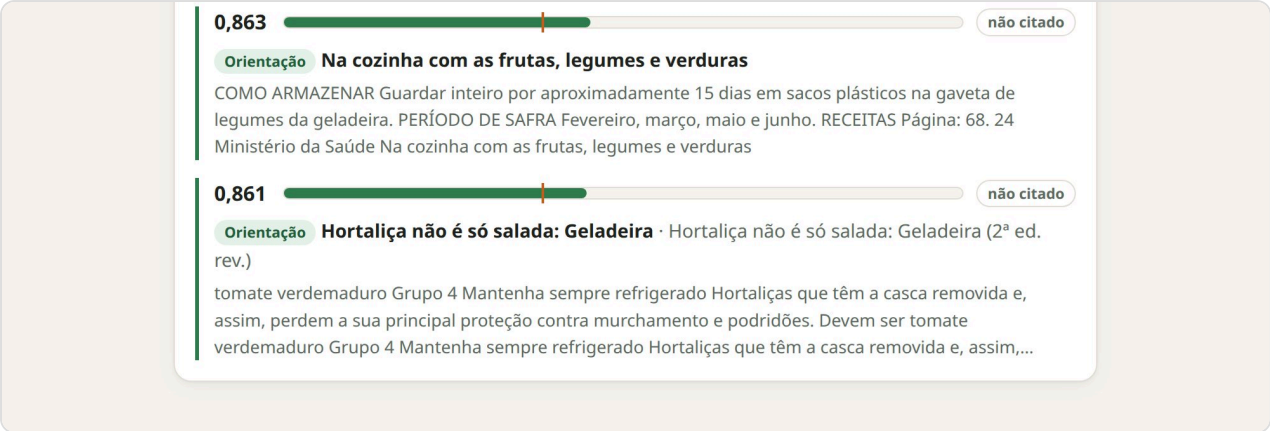


Figura 5. Fim do painel: os demais trechos, todos acima da linha do limiar.

6.2 Pedido de refeição com vários ingredientes

1 Pergunta de um teste real da equipe: "quero fazer um almoço completo, ingredientes que tenho (podem ser várias receitas): arroz, feijão, carne, alface".

Antes da busca por ingrediente, essa pergunta voltava "não encontrei": o vetor de "almoço completo" puxava textos gerais do Guia sobre refeições. 2 Agora o sistema também busca uma receita para cada ingrediente (Carne de Rolo, Feijoada a la Vidigal, entre outras). 3 A resposta sugere uma refeição com essas receitas, e o código lista os ingredientes que faltam em cada uma (RN01). 4 As fontes são as receitas do afrodite.json e um trecho do "Na cozinha com as FLV".

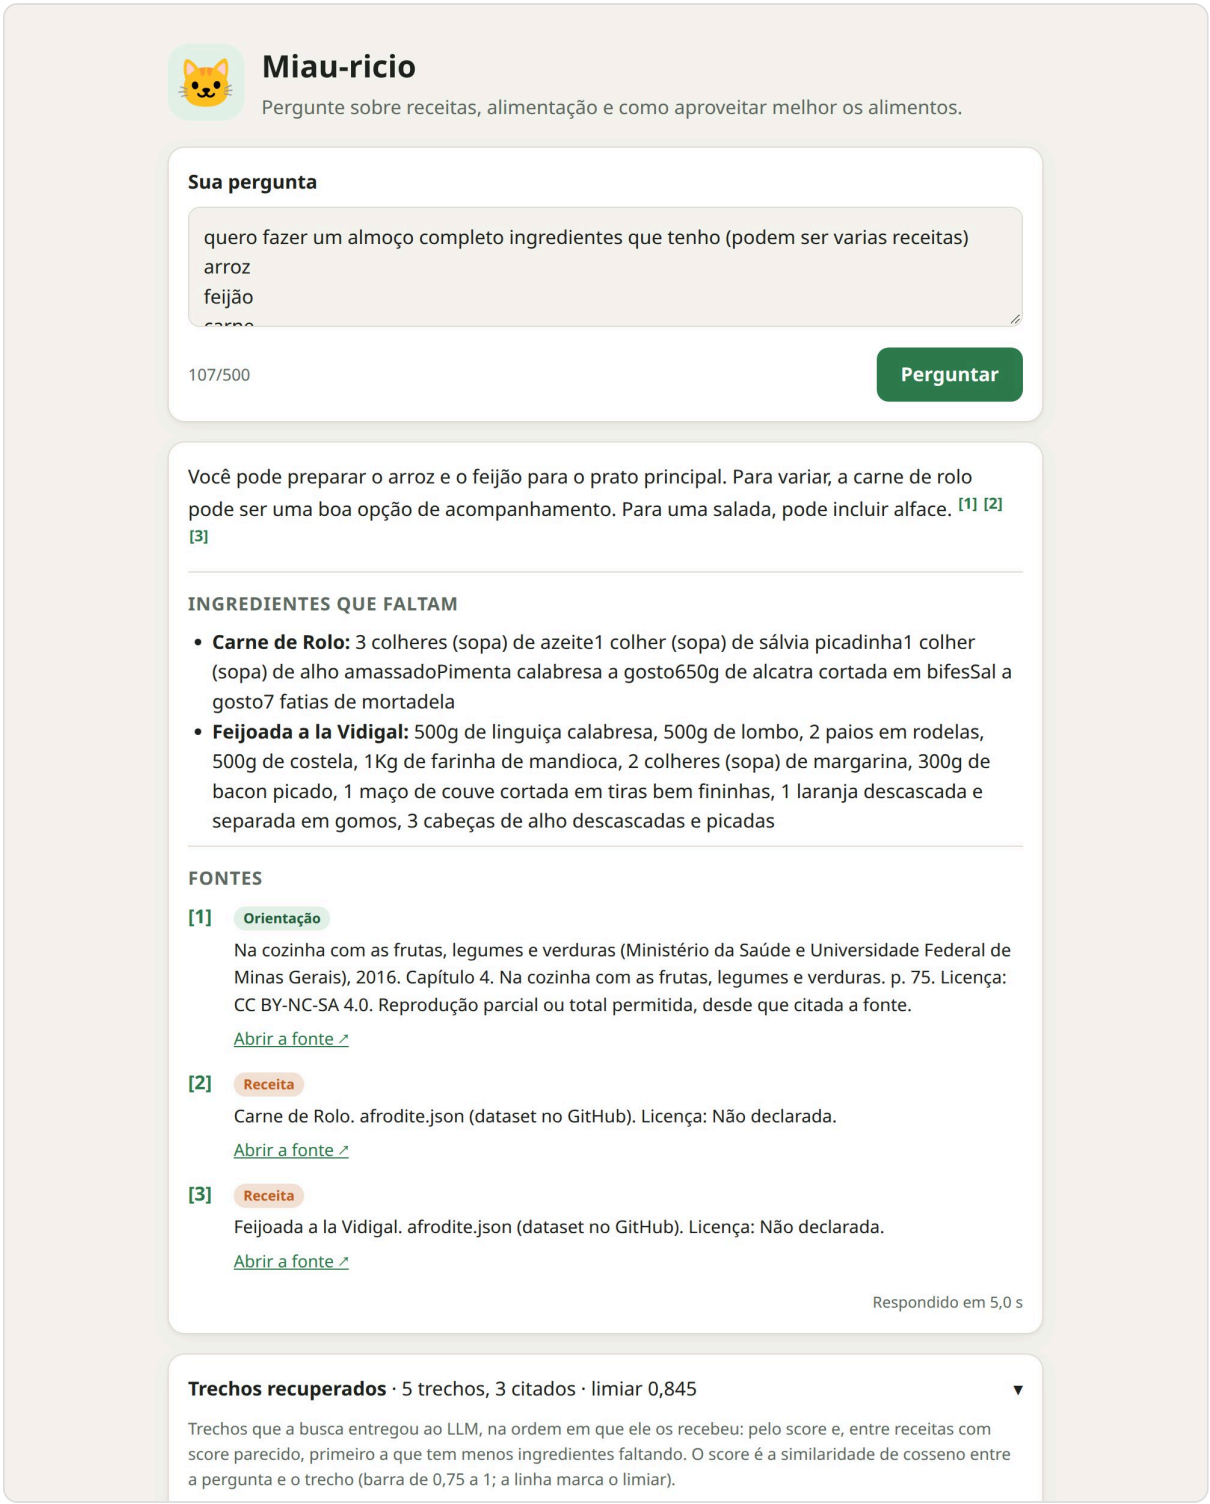


Figura 6. Resposta com as receitas, os ingredientes que faltam e as fontes.



Figura 7. Trechos recuperados: receitas da busca por ingrediente e da busca geral, com os que foram citados.

O que esta demonstração mostra de limitação: a lista de ingredientes de algumas receitas do afrodite.json vem colada numa linha só ("azeite1 colher (sopa) de sálvia..."), o que atrapalha a contagem do que falta. E a qualidade das sugestões depende das receitas da base, que não foi pensada para montar cardápios.

6.3 Pergunta respondida por uma fonte nova

1 "Posso dar açúcar para uma criança menor de 2 anos?" Antes da ampliação da base, essa pergunta não tinha resposta.

2 Os 5 trechos recuperados vêm do Guia Alimentar para Crianças Menores de 2 Anos, acrescentado nesta semana, com scores de 0,88 a 0,91. O primeiro diz literalmente "não oferecer açúcar nem preparações ou produtos que contenham açúcar à criança menor de 2 anos". 3 A resposta recomenda não oferecer açúcar e explica por quê. 4 As duas fontes citadas são páginas diferentes do mesmo guia (p. 222 e p. 103).

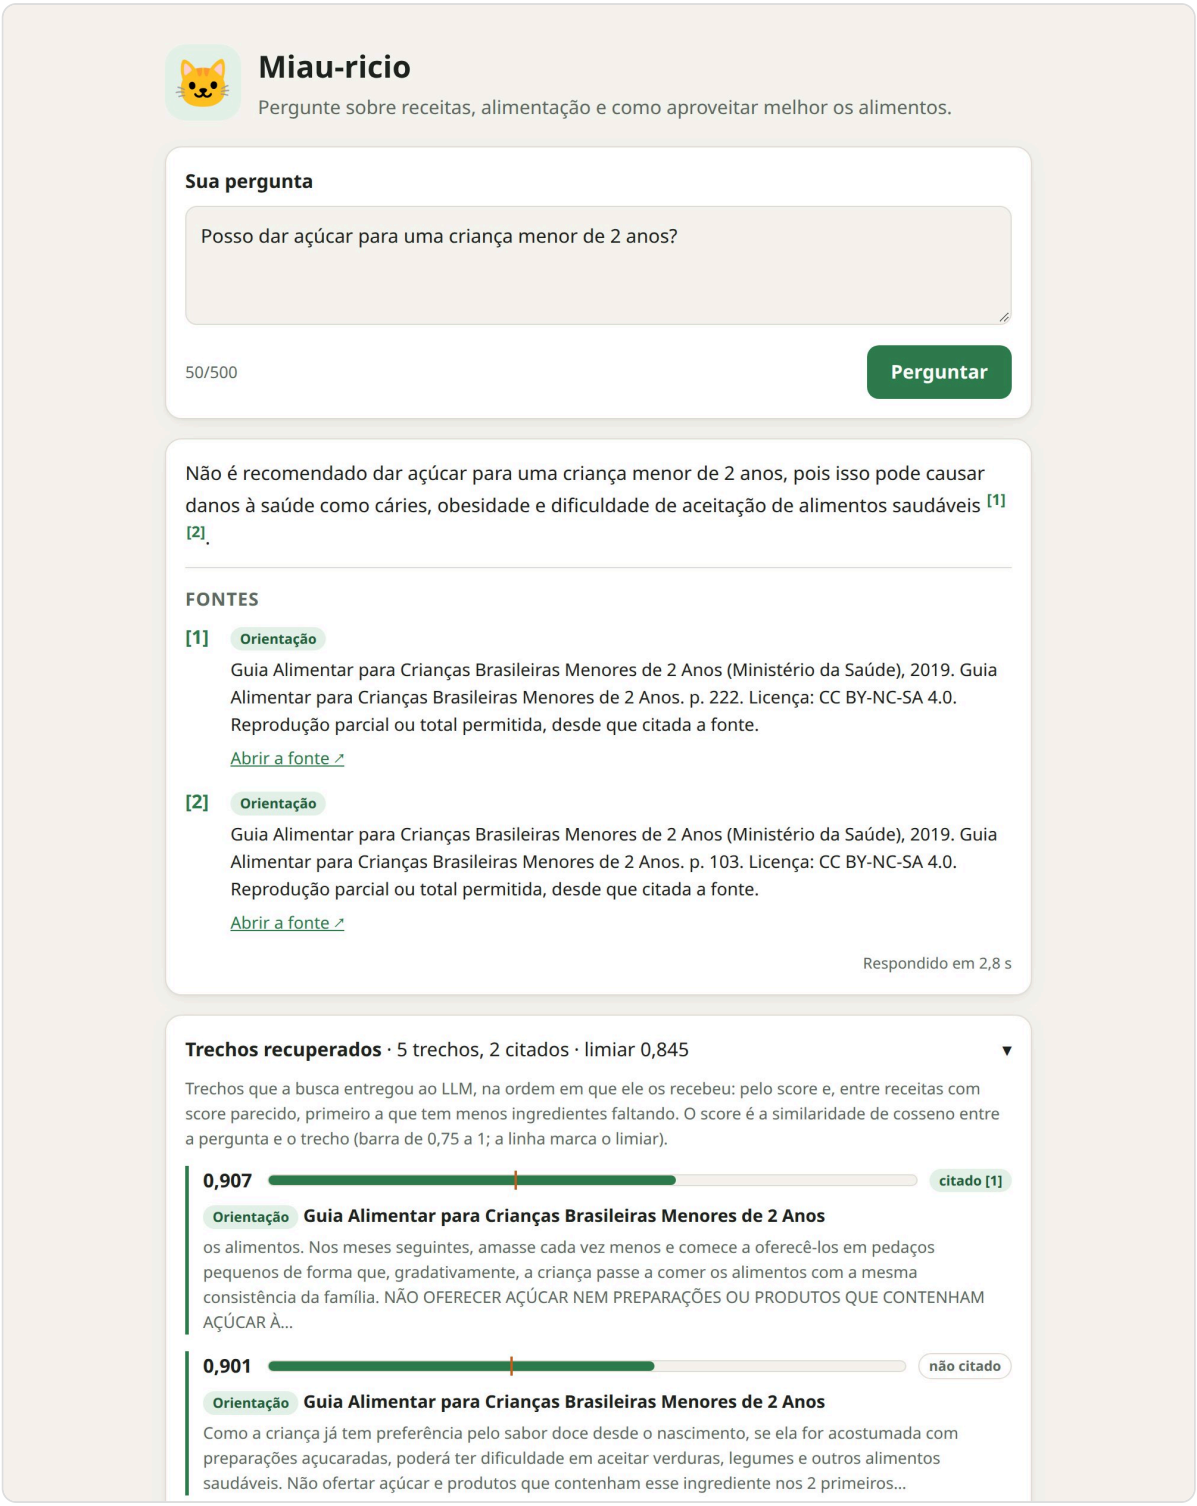


Figura 8. Resposta baseada no Guia Alimentar para Crianças Menores de 2 Anos.

6.4 Pergunta fora da base (RN11)

1 "Qual o melhor time de futebol do Brasil?"

2 Os trechos mais próximos têm score entre 0,80 e 0,82, todos abaixo do limiar de 0,845; o painel mostra cada um como "abaixo do limiar". 3 Nenhum trecho é entregue ao LLM, e a resposta diz que não encontrou a informação. 4 Não há fontes. É o comportamento da RN11: na dúvida, o sistema prefere não responder a inventar.

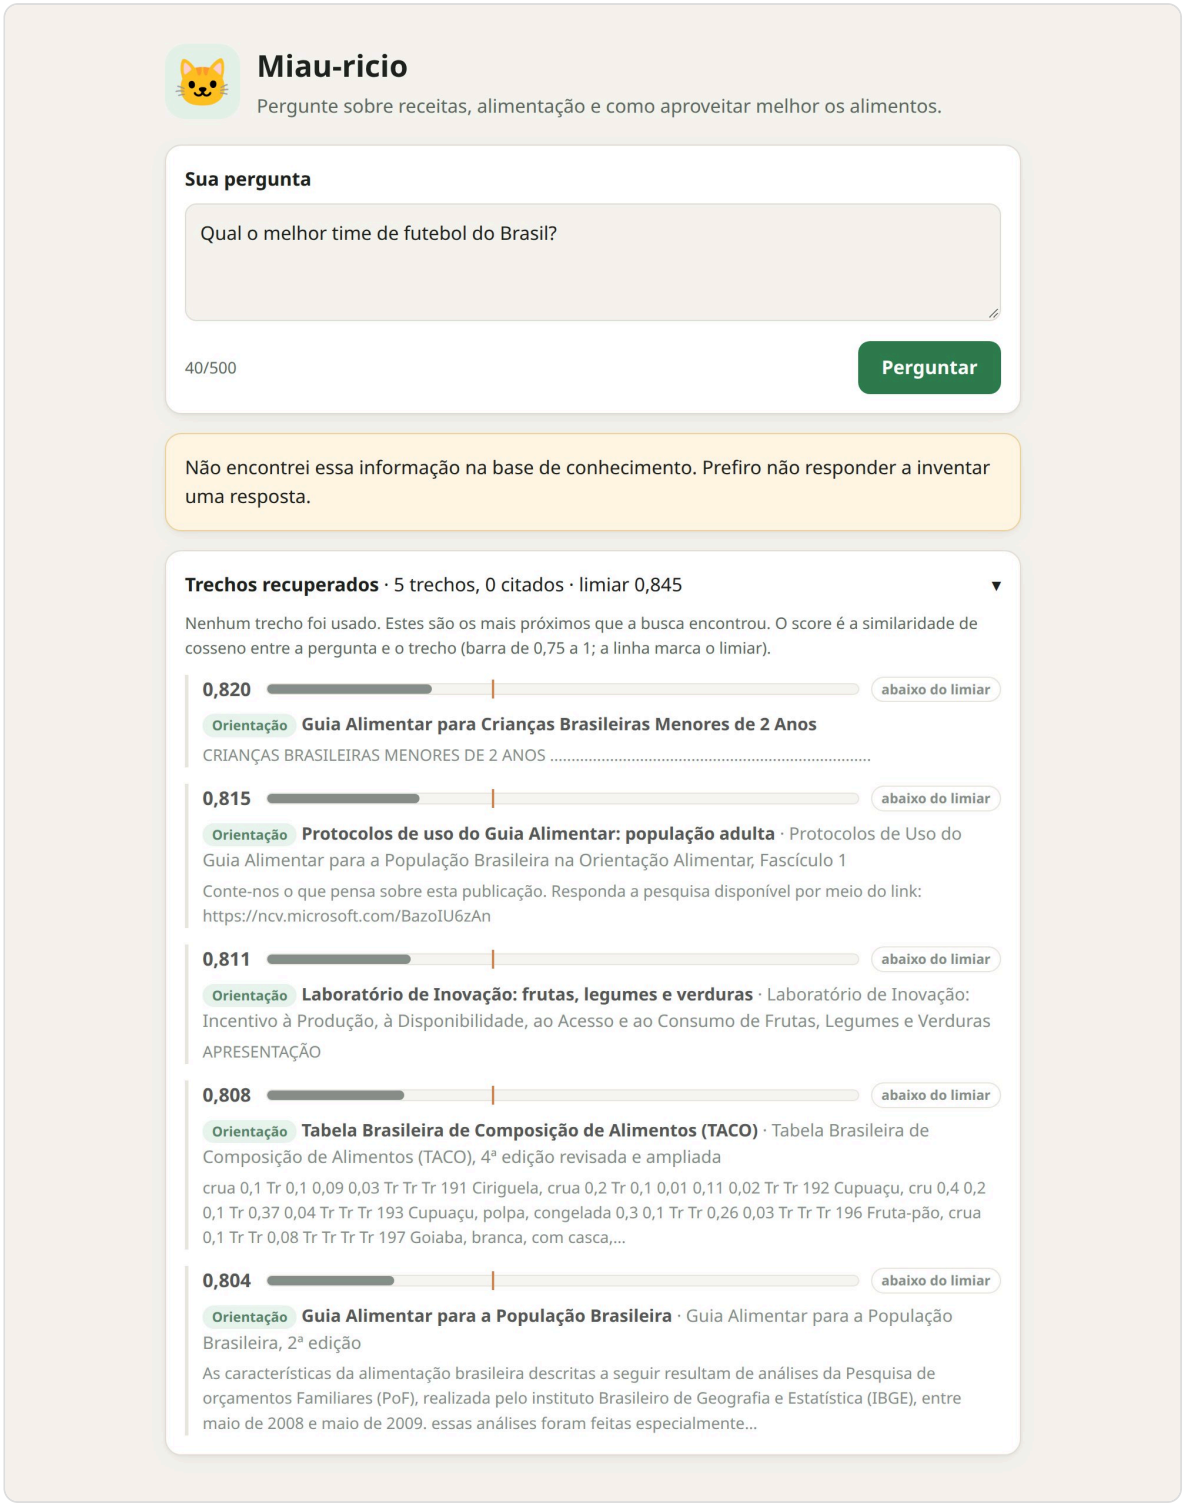


Figura 9. Pergunta fora da base: aviso de "não encontrei" e os trechos mais próximos, abaixo do limiar.

6.5 Pergunta de preço (RN04)

"Quanto custa o quilo do arroz hoje?" Uma regra determinística reconhece a pergunta de preço atual e responde com o aviso, sem consultar a base nem o LLM. Preços vêm do contexto de preços do EconoMIA, com data, fonte e origem (RN02 e RN03), e nunca do RAG.

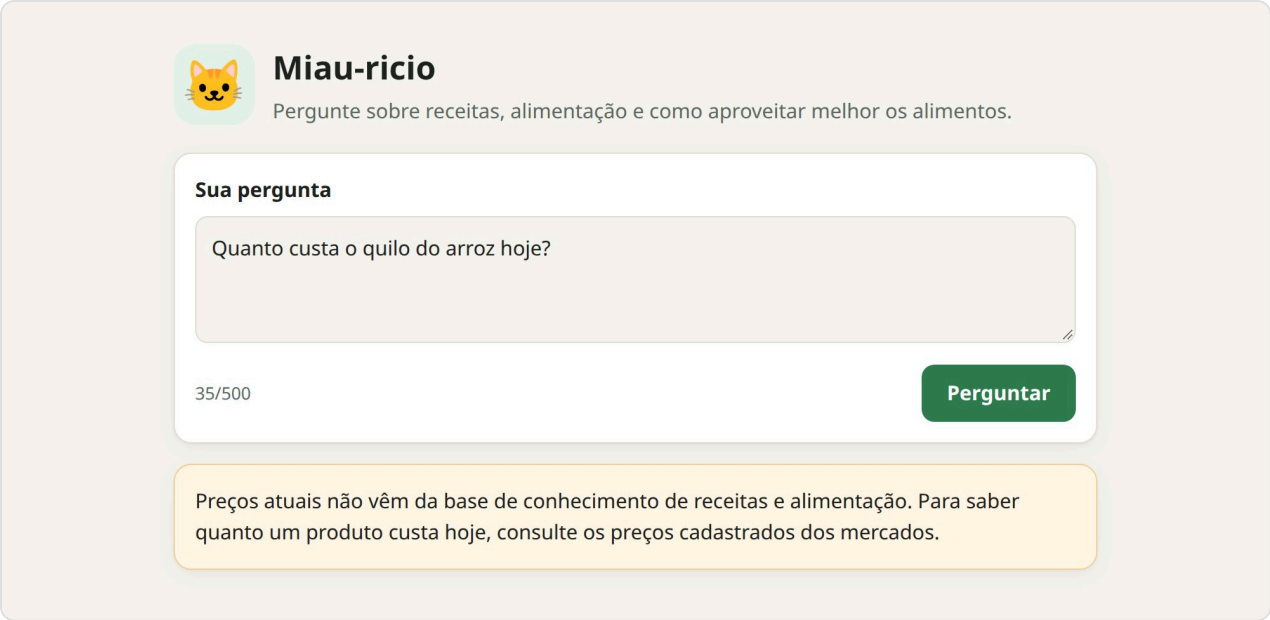


Figura 10. Pergunta de preço: aviso da RN04.

6.6 Tela no celular

A tela é responsiva. Pergunta: "Como aproveitar cascas e talos de legumes?" (aproveitamento integral, contra o desperdício).

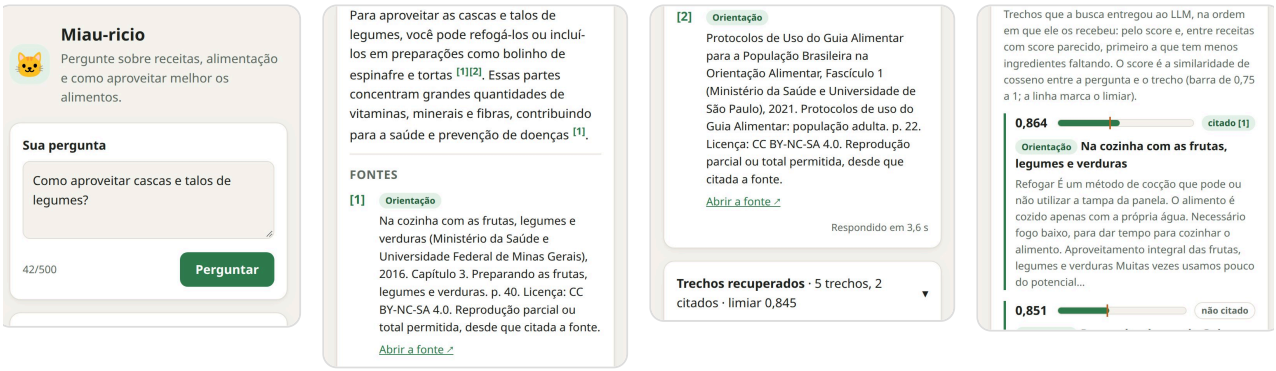


Figura 11. A mesma tela numa largura de celular (390 px), em quatro partes, de cima para baixo.

6.7 Linha de comando e API

O mesmo caso de uso atende a linha de comando, usada no desenvolvimento e no notebook de demonstração, e a API consumida pela tela.

```
linha de comando
$ poetry run python -m economia.receitas.cli perguntar "Como congelar legumes?"
Pergunta: Como congelar legumes?
Coleção: base_conhecimento_e5 | limiar: 0.845

Trechos recuperados (acima do limiar):
  1. [0.862] conhecimento: Hortaliça não é só salada: Congelador
  2. [0.861] conhecimento: Na cozinha com as frutas, legumes e verduras
  3. [0.856] conhecimento: Guia Alimentar para Crianças Brasileiras Menores de 2 Anos
  4. [0.854] receita: Sopa De Legumes
  5. [0.852] conhecimento: Hortaliça não é só salada: Congelador

Resposta (4 s):
Para congelar legumes, é importante prepará-los corretamente. Antes de congelar, remova as partes
danificadas, a casca e as sementes. Lave-as em água corrente e enxugue-as com um pano de …

Fontes:
  [1] Hortaliça não é só salada: Congelador (2ª ed. rev.) (Embrapa Hortaliças), 2020. Hortaliça não é
só salada: Congelador. p. 2. https://www.infoteca.cnptia.embrapa.br/infoteca/handle/d…
```

Comando `perguntar`: trechos recuperados com o score, resposta e fontes (texto cortado para caber na página).

API

```
$ curl -s -X POST localhost:8010/api/v1/receitas/perguntas -H "Content-Type: application/json" -d
'{"pergunta": "O que é comensalidade?"}' | jq
{
  "texto": "A comensalidade é o ato de compartilhar a mesa ou a refeição com outro, ou seja, é o
alimentar-se em conjunto, um momento de interação entre duas ou mais pessoas em uma situaç…
  "encontrou": true,
  "fontes": [
    {
      "numero": 1,
      "titulo": "Impactos da pandemia na alimentação e na comensalidade",
      "descricao": "Impactos da pandemia de Covid-19 na alimentação e comensalidade (Revista de
Alimentação e Cultura das Américas (RACA), Fiocruz), 2024. Impactos da pandemia na alimenta…
      "url": "https://raca.fiocruz.br/index.php/raca/article/view/192",
      "licenca": "CC BY 4.0",
      "tipo": "conhecimento"
    }
  ],
  "ingredientes_disponiveis": [],
  "faltando": [],
  "trechos_recuperados": [
    {
      "posicao": 1,
      "titulo": "Impactos da pandemia na alimentação e na comensalidade",
      "tipo": "conhecimento",
      "origem": "Impactos da pandemia de Covid-19 na alimentação e comensalidade",
      "score": 0.8733,
      "acima_do_limiar": true,
      "fonte": null,
      "resumo": "comer ou não, as horas em que se deve comer, o número de refeições diárias, com quem
se deve comer, qual a etiqueta que se deve seguir, etc, regras que todos seguem sem s…
    },
    {
      "posicao": 2,
      "titulo": "Impactos da pandemia na alimentação e na comensalidade",
      "tipo": "conhecimento",
      "origem": "Impactos da pandemia de Covid-19 na alimentação e comensalidade",
      "score": 0.8711,
      "acima_do_limiar": true,
      "fonte": 1,
      "resumo": "tempo durante uma política de permanência obrigatória em casa, como também de
redescobrir laços familiares. Tradicionalmente, o preparo dos alimentos faz parte do cuidado…
    }
  ],
  "limiar": 0.845,
  "segundos": 1.5
}
  (fontes e trechos_recuperados cortados para caber na página)
```

Chamada à API com `curl`: o JSON traz o texto, as fontes numeradas, os trechos recuperados com o score e o limiar.

7. Avaliação

Para medir as mudanças, a equipe montou um conjunto de **67 perguntas com gabarito** (`data/avaliacao/perguntas_rag_v2.json`), em 13 categorias: receitas em português e entre idiomas, Guia Alimentar, conservação, nutrição (TACO), alimentação infantil, desperdício, segurança dos alimentos, comportamento alimentar, erros de digitação, 10 perguntas sem resposta na base e 3 de preço. Cada pergunta tem um comportamento esperado: responder, dizer que não encontrou ou avisar sobre o preço. Na avaliação, o LLM roda com temperatura 0 e semente fixa, para que duas execuções sejam comparáveis.

7.1 Recuperação: base de 7 para 20 fontes

Métrica	7 fontes	20 fontes
Recall@5 (o trecho certo está entre os 5 primeiros)	0,50	**0,83**
MRR (posição do primeiro trecho certo)	0,44	**0,76**
Categorias novas (nutrição, infantil, comportamento, segurança)	0,00	0,60 a 1,00

comparação das execuções

```
$ poetry run python -m economia.receitas.cli comparar-execucoes
data/avaliacao/v2/recuperacao_antes.json data/avaliacao/v2/recuperacao_depois.json
Comparação (recuperacao): recuperacao_antes.json → recuperacao_depois.json

métrica                       antes   depois diferença
recall                        0.500    0.833    +0.333
mrr                           0.435    0.764    +0.329
score_medio_com_resposta      0.869    0.881    +0.012
score_medio_sem_resposta      0.822    0.832    +0.010
separacao                    -0.034   -0.012    +0.021
latencia_media                0.040    0.034    -0.006

Por categoria:
  alimentacao_infantil     recall 0.000 → 1.000 (+1.000) | mrr 0.000 → 1.000 (+1.000)
  comportamento_alimentar  recall 0.000 → 1.000 (+1.000) | mrr 0.000 → 1.000 (+1.000)
  conservacao              recall 1.000 → 1.000 (+0.000) | mrr 1.000 → 1.000 (+0.000)
  desperdicio              recall 0.500 → 1.000 (+0.500) | mrr 0.312 → 1.000 (+0.688)
  guia_alimentar           recall 1.000 → 0.833 (-0.167) | mrr 0.917 → 0.667 (-0.250)
  nutricao                 recall 0.000 → 1.000 (+1.000) | mrr 0.000 → 1.000 (+1.000)
  orientacao_nutricional   recall 0.500 → 1.000 (+0.500) | mrr 0.500 → 1.000 (+0.500)
  receita_entre_idiomas    recall 0.200 → 0.200 (+0.000) | mrr 0.050 → 0.050 (+0.000)
  receita_pt               recall 0.875 → 0.875 (+0.000) | mrr 0.688 → 0.688 (+0.000)
  robustez                 recall 0.800 → 0.800 (+0.000) | mrr 0.800 → 0.800 (+0.000)
  seguranca_alimentar      recall 0.000 → 0.600 (+0.600) | mrr 0.000 → 0.500 (+0.500)
  sem_resposta             recall — → — (—) | mrr — → — (—)
```

7.2 Respostas: do LLM sem citação à resposta estruturada

Com a base ampliada, o gargalo passou a ser o LLM: ele respondia sem citar os trechos, e o sistema descartava a resposta (RN10). Três mudanças resolveram isso: um prompt novo, a resposta em JSON com a lista dos trechos usados e uma segunda tentativa quando falta citação.

Configuração	Acurácia	Taxa de resposta	Recusa correta	Aviso de preço
Prompt v1, texto livre (20 fontes)	48%	35%	100%	100%
v1 + segunda tentativa	72%	65%	100%	100%
Prompt v2 com resposta estruturada (JSON)	91%	89%	100%	100%
v2 + segunda tentativa + busca por ingrediente (usada na demonstração)	**93%**	**91%**	100%	100%

comparação das execuções

```
$ poetry run python -m economia.receitas.cli comparar-execucoes data/avaliacao/v2/respostas_depois.json
data/avaliacao/v2/respostas_v2_busca_por_ingrediente.json
Comparação (respostas): respostas_depois.json → respostas_v2_busca_por_ingrediente.json

métrica                       antes   depois diferença
acuracia                      0.478    0.925    +0.448
taxa_de_resposta              0.352    0.907    +0.556
recusa_correta                1.000    1.000    +0.000
aviso_de_preco                1.000    1.000    +0.000
fonte_esperada                0.842    0.735    -0.107
latencia_media                2.891    2.514    -0.377

Por categoria:
  alimentacao_infantil     acuracia 0.600 → 1.000 (+0.400) | fonte_esperada 1.000 → 1.000 (+0.000)
  comportamento_alimentar  acuracia 0.667 → 1.000 (+0.333) | fonte_esperada 1.000 → 1.000 (+0.000)
  conservacao              acuracia 0.167 → 1.000 (+0.833) | fonte_esperada 1.000 → 0.833 (-0.167)
  desperdicio              acuracia 0.750 → 0.750 (+0.000) | fonte_esperada 1.000 → 1.000 (+0.000)
  guia_alimentar           acuracia 0.000 → 1.000 (+1.000) | fonte_esperada — → 0.667 (—)
  nutricao                 acuracia 0.200 → 0.400 (+0.200) | fonte_esperada 1.000 → 1.000 (+0.000)
  orientacao_nutricional   acuracia 1.000 → 1.000 (+0.000) | fonte_esperada 1.000 → 1.000 (+0.000)
  preco                    acuracia 1.000 → 1.000 (+0.000) | fonte_esperada — → — (—)
  receita_entre_idiomas    acuracia 0.200 → 1.000 (+0.800) | fonte_esperada 0.000 → 0.000 (+0.000)
  receita_pt               acuracia 0.375 → 0.875 (+0.500) | fonte_esperada 1.000 → 0.714 (-0.286)
  robustez                 acuracia 0.200 → 1.000 (+0.800) | fonte_esperada 1.000 → 0.800 (-0.200)
  seguranca_alimentar      acuracia 0.400 → 1.000 (+0.600) | fonte_esperada 0.000 → 0.600 (+0.600)
  sem_resposta             acuracia 1.000 → 1.000 (+0.000) | fonte_esperada — → — (—)
```

testes automatizados

```
$ poetry run pytest -q
.........................................                                [100%]
187 passed in 1.28s

$ cd frontend && npm test
 ✓ src/escala.test.ts (4 tests) 4ms
 ✓ src/citacoes.test.ts (7 tests) 5ms
 ✓ src/api.test.ts (4 tests) 19ms
 Test Files  3 passed (3)
      Tests  15 passed (15)
```

187 testes de Python (unidade e cenários BDD) e 15 testes do front passando.

8. Limitações e próximos passos

- **Números da TACO.** A busca acha a tabela certa, mas, dividida por página como texto, a tabela perde a ligação entre os números e as colunas, e o LLM chegou a ler o valor errado (2,9 g de proteína no ovo cozido, contra 13,3 g na TACO). Valores nutricionais devem vir de uma consulta estruturada, como cálculo determinístico (issue #22, RN01).
- **Fidelidade não medida.** A avaliação confere o comportamento e a fonte citada, não se cada frase é fiel ao trecho. O próximo passo é medir a fidelidade (*faithfulness*) com o Langfuse (#29).
- **Receitas entre idiomas.** A busca acerta pouco a receita exata do RecipeNLG para perguntas em português (Recall@5 de 0,20). A resposta usa receitas parecidas do afrodite.json.
- **Ingredientes que faltam.** O LLM às vezes sugere usar um ingrediente que está na lista do que falta. A lista certa é a do código, mostrada logo abaixo da resposta.
- **Dados das receitas.** O afrodite.json não declara licença nem a origem de cada receita, e parte das listas de ingredientes vem mal formatada.
- **LLM local.** O `qwen2.5:7b` responde em 2 a 15 s com GPU. Na CPU da VM de produção, uma resposta pode levar minutos. A escolha do provedor para a produção segue na #13.

9. Como reproduzir

1. Subir o Qdrant (`docker compose up -d`) e o Ollama (`ollama pull qwen2.5:7b`).
2. Instalar as dependências (`poetry install`), baixar os documentos-fonte (comandos em `specs/15-rag-receitas/plano-v1.md`) e indexar: `poetry run python -m economia.receitas.cli indexar` .
3. No `.env` , ativar a configuração medida: `PROMPT_DE_RESPOSTA=resposta_com_fontes_v2` , `RESPOSTA_ESTRUTURADA=true` , `SEGUNDA_TENTATIVA_DE_CITACAO=true` .
4. Subir a API (`poetry run uvicorn economia.api.app:app --port 8000`) e a tela (`cd frontend && npm install && npm run dev`), e abrir `http://localhost:5173` . Um link como `http://localhost:5173/?pergunta=Como%20congelar%20legumes%3F` já abre com a pergunta enviada.

Documentos de referência no repositório: `docs/semana-2/estrategia-rag.md` (chunking, embeddings e banco vetorial), `docs/semana-2/pipeline-ingestao.md` , `docs/semana-2/avaliacao-rag.md` (avaliação completa), `docs/arquitetura/visao-geral.md` , `data/base-conhecimento/FONTES.md` e as specs `specs/15-rag-receitas` , `specs/16-ampliar-base-conhecimento` e `specs/24-endpoint-rag` .